

# 显著性检测领域之 feature contrasts 和 priors

朱亚菲

2015 年 1 月

## 目录

<b>1</b>	<b>引言</b>	<b>2</b>
1.1	显著性检测	2
1.2	features	2
1.3	feature contrasts	3
1.4	color space	3
<b>2</b>	<b>基于像素点的 feature contrasts</b>	<b>5</b>
2.1	颜色	5
2.2	SIFT 特征	5
<b>3</b>	<b>基于区域的 feature contrasts</b>	<b>6</b>
3.1	颜色	6
3.1.1	Color Contrast	6
3.1.2	颜色直方图	6
3.2	纹理特征	8
3.3	位置特征	9
3.4	形状特征	9
3.4.1	区域面积	9
3.4.2	奇异值特征	9
3.4.3	HOG 特征	10
3.5	Visual Complexity Contrast	12
3.6	Background Weighted Contrast	12
<b>4</b>	<b>Hierarchical over-segmentation</b>	<b>13</b>

<b>5</b>	<b>Priors</b>	<b>13</b>
5.1	Center Prior 或 Location Prior	13
5.2	Backgroundness Prior	13
5.3	Boundary connectivity prior	15
5.4	Color Prior	16
5.5	Objectness Prior	16
5.6	Smoothness Prior	17
5.7	Focusness Prior	18
<b>6</b>	<b>Feature Contrasts/Priors 的融合</b>	<b>18</b>
6.1	相乘	18
6.2	相加	19
6.3	利用机器学习进行优化	19
6.3.1	最小二乘法	19
6.3.2	条件随机场	20
6.3.3	马尔可夫随机场	20

## 1. 引言

### 1.1 显著性检测

人类视觉系统对复杂场景具有强适应性，神经生理和心理研究表明人眼面临复杂场景时，会迅速将注意力集中在少数重要区域，并利用有限的处理能力对其优先处理。图像显著性检测的目的是在图像中快速有效地找到重要并且信息量大的区域 [11]。目前在图像重定向、图像分类、图像分割等领域都有广泛的应用。

目前大多数显著性检测方法都是基于自底向上的计算框架。归纳起来通常分为三步：1. 特征提取，提取多种视觉特征，例如亮度、颜色、纹理等。2. 求像素或区域间的对比度。3. 求显著性

### 1.2 features

图像特征提取是图像分析与图像识别的前提，它是将高维的图像数据进行简化表达最有效的方式，从一幅图像的  $M \times N \times 3$  的数据矩阵中，我们看不出任何信息，所以我们必须根据这些数据提取出图像中的关键信息，一些基本元件以及它们的关系。

图像特征可分为全局特征和局部特征<sup>1</sup>。其最大的区别是特征提取的空间范围不同。全局特征是从整个图像中提取的特征，而局部特征是从图像区域中提取的特征。全局特征容易受到环境的干扰，光照、旋转、噪声等不利因素都会影响全局特征。相比而言，局部特征点，往往对应着图像中的一些线条交叉、明暗变化的结构中，受到的干扰也少。

总的来说，全局特征是对图像内容的高度抽象的概括。如果用户对整个图像的整体感兴趣，而不是对前景本身感兴趣的话，用全局特征来描述图像是比较合适的。但是无法分辨出前景和背景却是全局特征本身就有的劣势，特别是在关注的对象受到遮挡等影响的时候，全局特征很有可能就被破坏掉了。

在显著性检测中，由于关注的是显著目标，并且是在同一幅图像中进行中央-周围/局部/全局对比，而不是在图像间进行比较，因此用到的应该都是局部特征。显著性检测领域所说的局部和全局方法是指对某一像素或区域，在计算其对比度时是与周围相比还是与图像中所有其它像素或区域相比。

英国 Oxford 大学的 Andrea Validi，他是 VLFeat(Vision Lab Features Library) 的发起者和主要作者。VLFeat 官方主页：[vlfeat.org](http://vlfeat.org)。它一个实现了计算机视觉领域诸多算法的开源库，包括 SIFT, HOG 等等。底层代码用 C 语言实现，并提供了 MATLAB 接口。支持 Windows, Mac OS X 和 Linux。VLFeat 目前正在逐渐实现其他常用的特征描述子。和 OpenCV 相比，VLFeat 是一个轻量级的库，主要实现了在特征提取和聚类方面的高效算法，可以用在图像检索和物体识别领域中。

图像特征又可以分为低层次特征和高层次特征 [15]。其中低层次特征是不需要任何形状信息 (空间关系的信息) 就可以从图像中自动提取的基本特征。高层次特征提取关心的是在图像中找出形状。例如，要自动识别人脸，一种方法是提取组成部分特征。也就是说，需要提取眼睛、耳朵和鼻子这些主要的脸部特征。这些特征可以利用它们的形状找到：眼睛的白色部分是椭圆形的；嘴巴可以看做是两条直线，眉毛也一样。形状提取意味着找出它们的位置、朝向和尺寸。所有低层次方法都可以应用于高层次特征提取，从而在图像中找到形状。(这里将特征分为低层次特征和高层次特征是从广义还是狭义的角度我还没有搞清楚)

### 1.3 feature contrasts

对于一幅图像，人们会更加关注与周围物体的对比度差异大的区域。

### 1.4 color space

一般显著性检测方法中都会用到颜色特征，除了 RGB 颜色空间，另外两个常用的颜色空间就是 CIELab 和 HSV 颜色空间。

<sup>1</sup>更多局部特征见<http://www.sigvc.org/bbs/thread-165-1-1.html>

颜色空间 (也称为彩色模型、彩色空间或彩色系统) 的用途是在某些标准下用通常可以接受的方式方便地对彩色加以说明。

### 1) RGB 颜色模型

RGB 颜色空间是常用的表示彩色图像的一种颜色空间, 它是以红、绿、蓝三种颜色为基础, 亦称为“三原色”。所谓的“原色”是一种生物学概念, 是根据人眼对光线感知的生理作用来定义的。每一种颜色按亮度进行分类, 分成 256 个等级。不同比例的红、绿、蓝叠加, 能产生丰富的颜色。例如, 等比例的三原色进行相加可以产生白色, 红色与绿色相加产生黄色。可见, RGB 空间属于“叠加型”原色系统, 因此把 RGB 颜色空间作为最基础的颜色空间, 通过对 RGB 的非线性或线性变换可以获得其它的颜色空间。

### 2) CIELAB 颜色空间

在许多文献中, CIELAB 颜色空间也称 CIE 1976  $L^*a^*b^*$ (简称为 CIE  $L^*a^*b^*$ ) 颜色空间。CIELAB 颜色系统是使用最广泛的物体颜色度量方法, 并作为度量颜色的国际标准。CIE 1976  $L^*a^*b^*$  颜色空间是 CIE 1931 XYZ 颜色空间的一种数学变换的结果。

CIE 1976  $L^*a^*b^*$  颜色空间和 CIE 1931 XYZ 颜色空间的相同之处是, 它们都使用相同的基本原理, 即颜色是光、物体和观察者组合的结果, 三种基色值是用 CIE 定义的光、物体和观察者的数据进行计算得到的。

CIELAB 系统使用的坐标叫做对色坐标 (opponent color coordinate), 使用对色坐标的想法来自这样的概念: 颜色不能同时是红和绿, 或者同时是黄和蓝, 但颜色可以被认为是红和黄、红和蓝、绿和黄以及绿和蓝的组合。CIELAB 使用  $L^*$ ,  $a^*$  和  $b^*$  坐标轴定义 CIE 颜色空间。其中,  $L^*$  值代表光亮度, 其值从 0(黑色) 100(白色)。 $a^*$  和  $b^*$  代表色度坐标, 其中  $a^*$  代表红-绿轴,  $b^*$  代表黄-蓝轴, 它们的值从 0 10。 $a^* = b^* = 0$  表示无色, 因此  $L^*$  就代表从黑到白的比例系数。

### 3) HSV 颜色模型

HSV(Hue, Saturation, Value) 是根据颜色的直观特性由 A. R. Smith 在 1978 年创建的一种颜色空间, 也称六角锥体模型 (Hexcone Model)。

HSV 颜色模式是除了 RGB 颜色模式之外的另一种流行的颜色模式, RGB 被广泛运用于计算机中, 而 HSV 则用在电视显示方面。它更符合人们对颜色的描述 (什么颜色 (H), 深浅度如何 (S), 亮度如何 (V))。其实在电视机上菜单中的饱和度就是 S, 亮度就是 V。

如图 1, 色调 (H) 用与水平轴之间的角度来表示, 范围从 0 度到 360 度。六边形的顶点以 60 度为间隔。黄色位于 60 度处, 绿色在 120 度处而青色在 180 度处, 与红色相对。相补的颜色互成 180 度。

饱和度 (S) 从 0 到 1 变化。在此模型中它表示成所选色彩的纯度与该色彩的最大纯度 ( $S = 1$ ) 的比率。当  $S = 0.5$  时所选色彩的纯度为四分之一。当  $S = 0$  时, 只有灰度。

亮度值 (V) 从六边形顶点的 0 变化到顶部的 1，顶点表示白色。在六边形顶部的颜色强度最大。当  $V = 1, S = 1$  时，有纯色彩。白色是  $V = 1$  且  $S = 0$  的点。




图 1: HSV 颜色模型

## 2. 基于像素点的 feature contrasts

### 2.1 颜色

### 2.2 SIFT 特征

SIFT 特征 (Scale-invariant transform, 尺度不变特征变换) 由 David Lowe 在 1999 年 [12] 所发表, 2004 年 [13] 完善总结。它是一种计算机视觉的算法, 用来侦测与描述图像中的局部性特征, 它在空间尺度中寻找极值点, 并提取出其位置、尺度、旋转不变量。SIFT 算法提取的特征点具有尺度不变性, 也就是说, 同一物体在图像上不论尺度大小, 都能根据 SIFT 算法提取到相同的特征点。

简单来说, SIFT 算法就是用不同尺度 (标准差) 的高斯函数对图像进行平滑, 然后比较平滑后图像的差别, 差别大的像素就是特征明显的点。

尺度空间理论的目的是模拟图像数据的多尺度特征。高斯卷积核是实现尺度变换的唯一线性核, 于是一幅二维图像的尺度空间定义为:

$$L(x, y, e) = G(x, y, e) * I(x, y) \quad (1)$$

其中  $G(x, y, e)$  是尺度可变高斯函数,

$$G(x, y, e) = \frac{1}{2 * \pi * e^2} * \exp\left[-\frac{x^2 + y^2}{2e^2}\right] \quad (2)$$

$(x, y)$  是空间坐标,  $e$  是尺度坐标。

为了有效地在尺度空间检测到稳定的关键点, 提出了高斯差分尺度空间 (DOG scale-space)。利用不同尺度的高斯差分核与图像卷积生成。

$$D(x, y, e) = ((G(x, y, ke) - G(x, y, e)) * I(x, y) = L(x, y, ke) - L(x, y, e) \quad (3)$$

SIFT 特征一般用于匹配, 在 eye fixation prediction 中有用到, 而在显著性区域检测中没有见用的。

### 3. 基于区域的 feature contrasts

这里的 feature contrasts 是指由某种 visual cue(比如颜色、纹理、位置等) 对图像中两个区域  $r_i$ 、 $r_j$  求出的区域间对比度。

#### 3.1 颜色

##### 3.1.1 Color Contrast

论文 [19] 中用到, 公式如下:

$$C_i = \sum_{j=1}^n w(R_i) \Phi(i, j) \|c_i - c_j\|_2 \quad (4)$$

其中,  $c_i$  和  $c_j$  分别是区域  $R_i$  和  $R_j$  内颜色的均值,  $w(R_j)$  表示区域  $R_j$  内的像素个数,  $\Phi(i, j) = \exp\{-D(R_i, R_j)/\sigma^2\}$ 。

论文 [23] 中用到, 图像区域中方差不同的颜色之间的分布是相互独立的。区域  $r_i$  与  $r_j$  之间的 color contrast 定义如下:

$$D_c(r_i, r_j) = \|\mu_{c,i} - \mu_{c,j}\|^2 \cdot \left( \frac{\sigma_{c,i}^2}{n_i} + \frac{\sigma_{c,j}^2}{n_j} \right)^{-\frac{1}{2}} \quad (5)$$

其中  $\mu_{c,i}$  和  $\mu_{c,j}$  分别表示区域  $r_i$  和  $r_j$  内的颜色均值,  $\sigma_{c,i}^2$  和  $\sigma_{c,j}^2$  表示方差,  $n_i$  和  $n_j$  表示相应区域内像素的个数。

##### 3.1.2 颜色直方图

图像直方图是指统计图像中像素的灰度/颜色得到的图像灰度/颜色频数图。直方图由于其计算代价较小, 且具有图像平移、旋转、缩放不变性等优点, 广泛应用于图像处理的各个领域。Swain 和



Ballard 最先提出了使用颜色直方图作为图像颜色特征的代表方法。

传统颜色直方图描述方法存在以下问题：

- 1) 颜色特征维数高。以 8bit 的 RGB 颜色空间为例，全颜色数为  $256 \times 256 \times 256$  种颜色，如果以全颜色数统计直方图，则存储空间和计算复杂度都较大。
- 2) 颜色特征受光照影响。即对于两幅颜色分布很类似却因光照不同导致亮度差异大的图像，理论上，其颜色直方图应相似，但实际传统颜色直方图却不相似。
- 3) 不能表达相近颜色间相关性，即传统颜色直方图的颜色间完全独立，不能反映相近颜色间的关联。理论上，对于发生较小颜色偏移的两幅图像间应相似。如，一幅完全红色的图像与另一幅完全浅红色的图像间相似度较高。而实际传统颜色直方图却不相似。
- 4) 丢失空间位置信息，因此该特征无法区分颜色相同而空间分布不同的两幅图像。

得到图像颜色特征后需要定义颜色特征的相似度量公式，以表示两幅图像间颜色的相似性。不同的相似性度量公式对实际应用结果可能影响很大。因此需要研究如何选择或设计合适的相似性度量算法。

显著性 Models 中，CB [6]、DRFI [7]、HC/RC [2]、HDCT [9] 方法都用到了颜色直方图。

DRFI 方法中关于图像 RGB 空间的颜色直方图代码如下：

```

1 image = imread('3.jpg');
2 image_rgb = im2double( image );
3 RGB_bins = [16 16 16];
4 R = image_rgb(:,:,1);
5 G = image_rgb(:,:,2);
6 B = image_rgb(:,:,3);
7 rr = min( floor(R*RGB_bins(1)) + 1, RGB_bins(1) );
8 gg = min( floor(G*RGB_bins(2)) + 1, RGB_bins(2) );
9 bb = min( floor(B*RGB_bins(3)) + 1, RGB_bins(3) );
10 Q_rgb = (rr-1) * RGB_bins(2) * RGB_bins(3) + ...
11         (gg-1) * RGB_bins(3) + ...
12         bb + 1;
```

首先对图像 ( $300 \times 400$ ) 的颜色空间进行量化，将颜色空间划分为若干个小的颜色区间，即直方图的 bin，例如将每个颜色通道量化为只有 16 个不同值，此时  $bin = 16 \times 16 \times 16$ ，然后计算矩阵  $Q(300 \times 400)$ ，用其中的值代表颜色，而不是用  $(r, g, b)$  向量表示颜色， $Q$  中有多少个不同值表示图像中有多少种颜色。结果如图 2。

对每个超像素区域，可以知道其中像素点的坐标值，能求出其对应到矩阵  $Q$  中的值，有多少个不




图 2: RGB 空间的颜色直方图

同值就代表该区域内有多少种不同的颜色，然后算该区域在  $1 - 16^3$  之间的颜色占的像素个数，没有的记为 0。对每个区域都能算出这样一个  $16^3$  维的向量，然后求区域之间的直方图的对比度，也就是求这样两个向量之间的距离。

### 3.2 纹理特征

图像纹理一直到现在都没有一个一致的、公认的定义，它在图像中是一个重要但是又不太容易描述出来的特征。纹理是人们将人类的视觉与触觉联系起来，进而形成一个视觉信息，它起源于人类对事物的触感。

LBP(Local Binary Pattern, 局部二值模式) 首先是由 Ojala 等人 [16] 于 1994 年提出，DRFI 方法 [7] 中用到。

LBP 有很多变种，或说改进。原始的 LBP 记录像素点与其周围像素点的对比信息，或说差异。对于图像上 9 个方格中中间方格 (方格中的值是像素点灰度值大小)，做一个阈值化处理。大于等于中心点像素的，标记为 1，小于的则标记为 0。最后将中心像素点周围的 11110001 二进制数化为十进制数，得到 LBP 值。如图 3 所示。




图 3: 原始 LBP






图 4: LBP

如图 4

### 3.3 位置特征

超像素区域中心与图像中心的距离

论文 [19] 中用到，公式如下：

$$H_i = \frac{1}{w(R_i)} \sum_{x_i \in R_i} \exp\{-\lambda \|x_i - x_c\|^2\} \quad (6)$$

其中  $(x_0, x_1 \dots)$  是区域  $R_i$  中的像素坐标集， $x_c$  是图像中心的坐标， $w(R_i)$  计算了区域  $R_i$  内的像素个数。由  $H_i$  的公式可看到，距离图像中心越近的区域拥有越大的权值。

HDCT [9] 中用到，

### 3.4 形状特征

#### 3.4.1 区域面积

该区域包含的超像素的个数

#### 3.4.2 奇异值特征

奇异值特征 (Singular Value Feature, SVF) [17] 被用来从测试图像中检测模糊区域，通常一幅图像中的模糊区域是背景的可能性较大。

### 3.4.3 HOG 特征

HOG(Histogram of Oriented Gradients, 方向梯度直方图) 特征最早是由法国国家计算机技术和控制研究所 (INRIA) 的 Navneet Dalal 和 Bill Triggs 在 2005 年发表在 CVPR 上的论文 [3] 中提出的。

Dalal 提出的 HOG 特征提取的过程如图 5, 进一步表述如下:

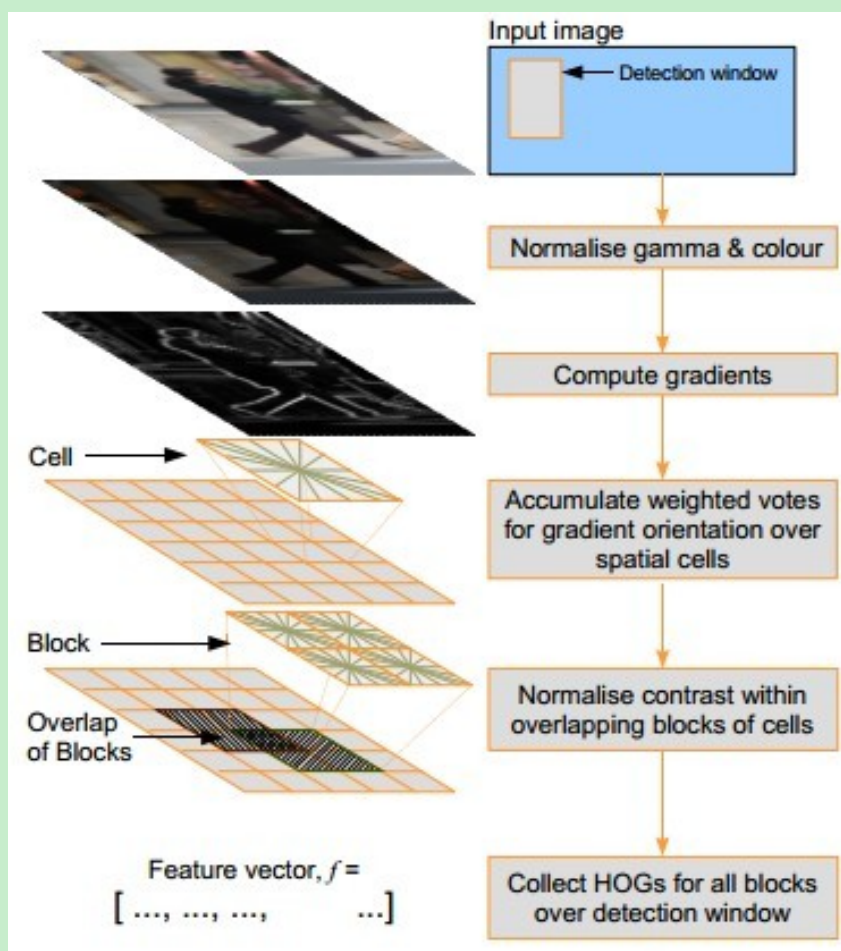


图 5: 算法流程图

#### 1. 灰度化

2. 采用 Gamma 校正法对输入图像进行颜色空间的标准化 (归一化); 目的是调节图像的对比度, 降低图像局部的阴影和光照变化所造成的影响, 同时可以抑制噪音的干扰。Gamma 压缩公式:

$$I(x, y) = I(x, y)^{gamma} \quad (7)$$

3. 计算图像每个像素的梯度 (包括大小和方向), 主要是为了捕获轮廓信息, 同时进一步弱化光照的干扰。

图像中像素点  $(x, y)$  的梯度为

$$G_x(x, y) = H(x + 1, y) - H(x - 1, y) \quad (8)$$

$$G_y(x, y) = H(x, y + 1) - H(x, y - 1) \quad (9)$$

式中  $G_x(x, y), G_y(x, y), H(x, y)$  分别表示输入图像中像素点  $(x, y)$  处的水平方向梯度、垂直方向梯度和灰度值。像素点  $(x, y)$  处的梯度幅值和梯度方向分别为：

$$G(x, y) = \sqrt{G_x(x, y)^2 + G_y(x, y)^2} \quad (10)$$

$$\alpha(x, y) = \tan^{-1}\left(\frac{G_y(x, y)}{G_x(x, y)}\right) \quad (11)$$

最常用的方法是：首先用  $[-1, 0, 1]$  梯度算子对原图像做卷积运算，得到  $x$  方向（水平方向，以向右为正方向）的梯度分量  $\text{gradscalx}$ ，然后用  $[1, 0, -1]^T$  梯度算子对原图像做卷积运算，得到  $y$  方向（竖直方向，以向上为正方向）的梯度分量  $\text{gradscalx}$ 。然后再用以上公式计算该像素点的梯度大小和方向。

4. 将图像每  $16 * 16$  (取其它也可以) 个像素分到一个 cell 中，对于  $256 * 256$  的图像来说，就分成了  $16 * 16$  个 cell 了。

5. 对于每个 cell 求其梯度方向直方图，通常取  $\text{bin} = 9$  (取其它也可以) 个方向 (特征)，也就是每  $360/9 = 40$  度分到一个方向，形成每个 cell 的 descriptor。如图 6，当某像素的梯度方向是  $20-40$  度，然后它的梯度大小是  $|\text{grad}|$ ，那么直方图第 2 个 bin 的计数就要加上  $|\text{grad}|$ 。




图 6: 梯度方向 bin 的划分

6. 由于局部光照的变化以及前景-背景对比度的变化，使得梯度强度的变化范围非常大。这就需要对梯度强度做归一化。归一化能够进一步地对光照、阴影和边缘进行压缩。为此可以将每  $2 * 2$  (取其它也可以) 个 cell 合成一个大的、空间上连通的 block，所以这里就有  $(16 - 1) * (16 - 1) = 225$  个 block。一个 block 内所有 cell 的特征向量串联起来便得到该 block 的 HOG 特征。这些 block 是互有

重叠的，这就意味着：每一个 cell 的特征会以不同的结果多次出现在最后的特征向量中。

7. 所以每个 block 中都有  $2 * 2 * 9$  个特征，一共有 225 个 block，所以总的特征有  $225 * 36$  个。

遇到的疑问：

1) 在显著性检测中，先将图像分割成区域，然后怎么提取该区域的 HOG 特征？

2) 一定要将彩色图像先转化为灰度图像才能提取 HOG 特征吗？

HDCT [9] 方法中用到 HOG 特征 [4]，采用的是 VLFeat 官网上的代码。论文中首先也是对图像进行超像素分割，然后求每个超像素区域内像素点坐标的平均值  $(x_i, y_i)$ ， $i$  代表第  $i$  个超像素区域，求该区域的 HOG 特征就是以该坐标点为中心的  $17 * 17$  的网格作为输入图像（只取该网格内图像 r 通道的值），17 作为 cellSize，然后对每个超像素区域得到一个 31 维的 HOG 特征向量。

### 3.5 Visual Complexity Contrast

论文 [23] 中用到，信息论中可以用熵来计算 visual complexity，区域  $r_i$  和  $r_j$  之间的 visual complexity contrast  $D_e(r_i, r_j)$  就被定义为

$$D_e(r_i, r_j) = [H(r_i) - H(r_j)]^2 \quad (12)$$

其中， $H(r_i)$  表示区域  $r_i$  内的熵

$$H(r_i) = \sum_{p=1}^{n_{c,i}} f(c_{p,i}) \cdot \log_2 f(c_{p,i}) \quad (13)$$

其中， $c_{p,i}$  是区域  $r_i$  中第  $p$  种颜色， $n_{c,i}$  区域  $r_i$  中包含的颜色个数， $f(c_{p,i})$  表示区域  $r_i$  中颜色  $c_{p,i}$  出现的概率。

### 3.6 Background Weighted Contrast

论文 [24] 中用到，其中将 background weighted contrast 定义为

$$wCtr(p) = \sum_{i=1}^N d_{app}(p, p_i) w_{spa}(p, p_i) w_i^{bg}, \quad (14)$$

## 4. Hierarchical over-segmentation

方法 TS [23] 中用到, hierarchical over-segmentation 是通过先对原图像进行超像素分割, 再通过迭代将每一分割层再分割成更精细的子区域来实现。

## 5. Priors

### 5.1 Center Prior 或 Location Prior

SDSP [22] 中将 Location Prior 描述为: 处于图像偏中央位置的物体更能吸引人的注意。这里 Location Prior 是按像素级计算的, 定义如下:

$$S_D(x) = \exp\left(-\frac{\|x - c\|_2^2}{\sigma_D^2}\right) \quad (15)$$

效果如图 7。




图 7: SDSP: Center Prior

论文 [20] 中用到 Convex-Hull-Based Center Prior, 即首先估计显著目标的中心位置  $(x_0, y_0)$ , 再计算每个超像素  $i$  的显著性:

$$S_{ce}(i) = \exp\left(-\frac{\|x_i - x_0\|^2}{2\sigma_x^2} - \frac{\|y_i - y_0\|^2}{2\sigma_y^2}\right) \quad (16)$$

### 5.2 Backgroundness Prior

通常是基于伪背景的假设, 即假设处于图像周围狭窄边界上的区域是背景区域。

2012 年, 论文 [18] 中提出了关于 background 的两种 prior, 叫做 boundary and connectivity priors. boundary prior 来源于摄影构图的基本规则, 大部分摄影师都不会将显著目标切断在视觉框架中, 也



就是说，位于图像边界上的通常是背景。这个 prior 比之前提出的 center prior 更通用一些，因为显著目标可能并不会正好位于图像正中央，例如三分构图法，但它们很少会处在图像边界上。connectivity prior 是从图像中背景的外观特征得来的，背景区域通常较大并且是同质的。也就是说，背景中绝大多数图像块可以很容易地彼此连接起来。如图 8。




图 8: Geodesic saliency 图例

首先对一幅图像构造无向图  $G = \{V, \varepsilon\}$ ，图中的节点由两部分（图像块  $\{P_i\}$  和伪背景节点  $B$ ）构成，即  $V = \{P_i\} \cup \{B\}$ 。边也包括两种类型，一种是 internal edges，连接了所有相邻的图像块，另一种是 boundary edges，连接了处于图像边界的块和背景节点，即  $\varepsilon = \{(P_i, P_j) | P_i \text{ 与 } P_j \text{ 相邻}\} \cup \{(P_i, B) | P_i \text{ 在图像边界上}\}$ 。

图像块  $P$  上的 geodesic saliency 被定义为沿着从  $P$  到背景节点  $B$  的最短路径上的边的权值的累加和。

$$saliency(P) = \min_{P_1=P, P_2, \dots, P_n=B} \sum_{i=1}^{n-1} weight(P_i, P_{i+1}), s.t. (P_i, P_{i+1}) \in \varepsilon \quad (17)$$

- 1、伪背景的节点是怎么找的？
- 2、如何求 internal edge weight？

internal edge weight 是相邻图像块之间的 appearance distance，采用的是一种简单有效的 weight clipping approach，图像块与块之间的 appearance distance 求的是两个块在 LAB 颜色空间上的颜色平均值的不同。对图像中的每一个块，算出它与所有 neighbors 的最小 appearance distance，然后取这些 distance 的均值作为“insignificance” distance threshold，当某距离比这个阈值小时就说明它是不重要的，将它置为 0。

- 3、如何求 boundary edge weight？

boundary edge weight 度量的是处于图像边界的图像块不是背景的可能性大小。当 boundary prior 是完全有效的时候，所有的 boundary edge weight 就都是 0。但现实没有这么理想化，显著目标只要



有哪怕一小部分落到了图像边界，也会产生不好的效果。这里可以通过用其他的显著性的方法来实现，已知图像边界上的块，计算每个块  $P_i$  的显著性作为 the weight of boundary edge( $P_i, B$ )。

论文 [21] 算法步骤如图 9，先对图像进行超像素分割，然后将分割后的图像映射为图，每个超像素为图中的节点。第一个阶段是将图像的每一条边界上 (共 4 条) 的节点看作是 labelled background queries，依次算图中的每个节点与这些 queries 的相关性来得到 4 幅 labelled maps，然后对其进行融合得到显著图。在第二阶段，对第一阶段得到的显著图二值化，然后将得到的 labelled foreground 节点看作是 salient queries，最终每个节点的显著度就是通过计算其与 foreground queries 的相关性得到。

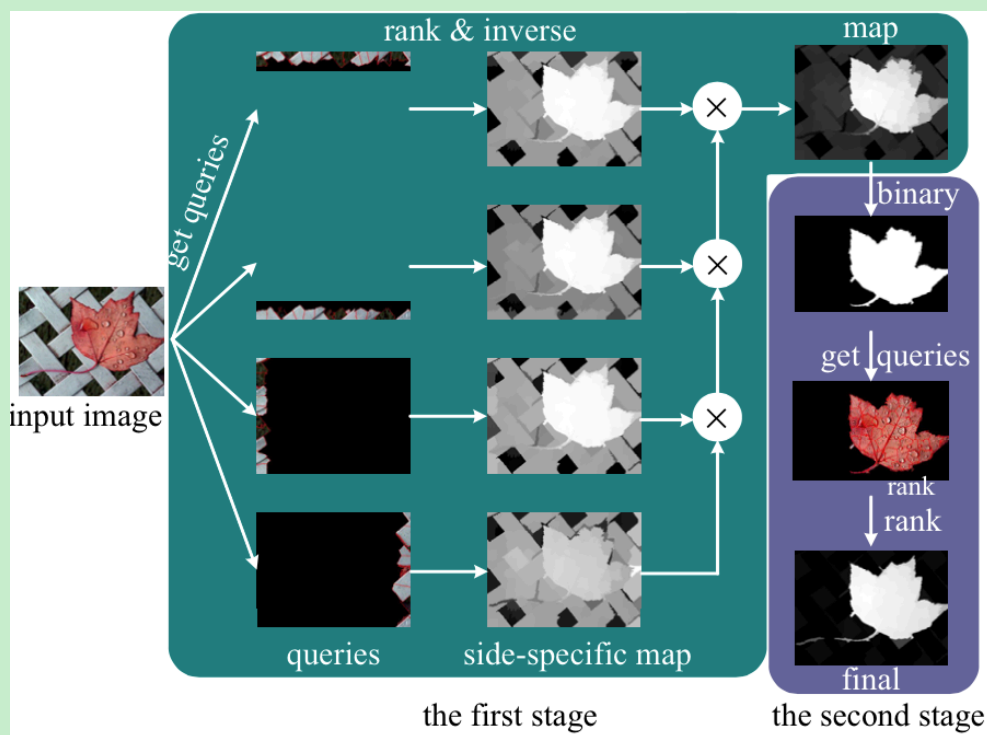


图 9: 算法步骤

论文 [5] 中也用到 backgroundness prior,

论文 [14] 中用到

### 5.3 Boundary connectivity prior

由于基于伪背景假设的显著目标检测方法在目标碰到图像边界时会失效，所以后来又提出了 boundary connectivity prior，这种 prior 被描述为：显著目标与图像边缘的连接程度比背景与边缘的连接程度小。

论文 [24] 中将一个区域内的 boundary connectivity score 定义为它沿图像边缘的长度与整个区域




图 10: SDSP: Color Prior

面积的比值:

$$BndCon(p) = \frac{Len_{bnd}(p)}{\sqrt{Area(p)}} \quad (18)$$

## 5.4 Color Prior

SDSP [22] 中将 Color Prior 描述为: 暖色 (例如红色和黄色) 比冷色 (例如绿色和蓝色) 更能吸引人类视觉系统的注意。先将图像由 RGB 颜色空间转换到  $CIEL^*a^*b$  空间,  $\{f_L(x)\}, \{f_a(x)\}, \{f_b(x)\}$  分别代表  $L^*$  通道,  $a^*$  通道和  $b^*$  通道。这里 Color Prior 是按像素级计算的, 定义如下:

$$S_c(x) = 1 - \exp\left(-\frac{f_{an}^2(x) + f_{bn}^2(x)}{\sigma_c^2}\right) \quad (19)$$

其中

$$f_{an}(x) = \frac{f_a(x) - \min a}{\max a - \min a}, f_{bn}(x) = \frac{f_b(x) - \min b}{\max b - \min b} \quad (20)$$

效果如图 10。

## 5.5 Objectness Prior

论文 [1] 中将 objectness 与 regional saliency 融合, 形成一个 graphical model。

论文 [8] 中从两个方面估计 objectness, 一是 pixel-level objectness estimation, 二是 region-level objectness estimation。

Pixel-level Objectness: 每个像素点的 objectness 值是以该像素点为中心的局部窗口内包含完整目

标的概率。在图像上随机抽样  $N$  个窗口，求每一个窗口  $w$  上用来表示 objectness 的概率值  $P(w)$ 。将所有窗口集记作  $W$ ，对每个像素点  $x$  可以得到它的像素级 objectness  $O_p(x)$

$$O_p(x) = \sum_{w \in W \text{ and } x \in w} P(W_x), \quad (21)$$

$w$  表示  $W$  中包含像素点  $x$  的任意窗口，论文中取  $N = 10000$ 。

Region-level Objectness: 对每个区域  $\Lambda_i$ ，计算该区域内的 region-level objectness  $O_r(\Lambda_i)$  为：

$$O_r(\Lambda_i) = \frac{1}{|\Lambda_i|} \sum_{x \in \Lambda_i} O_p(x). \quad (22)$$

计算完一个区域内的 objectness 后，把这个值赋给该区域内的所有像素。这样就可以得到整幅图像  $I$  的 objectness map，简称为  $O(I)$ 。

## 5.6 Smoothness Prior

论文 [20] 中用到，平滑约束通常是用在基于图的目标分割中，目的是使图像中相邻的像素拥有同样的 label 值。论文中先将图像分割成超像素，然后将其映射为图，每个超像素对应图中的节点，有共同的边界的超像素之间有一条边，边上的权值为  $w_{ij} \in W$ ：

$$w_{ij} = \exp\left(-\frac{\|c_i - c_j\|}{2\sigma_w^2}\right) \quad (23)$$

其中  $c_i$  和  $c_j$  是 CIELab 空间超像素区域内像素的颜色均值。可以看到关系矩阵  $W$  是一个稀疏矩阵。定义如下 saliency cost function 来表示这种 smoothness prior：

$$E(S) = \sum_i (S(i) - S_{in}(i))^2 + \lambda \sum_{i,j} w_{ij} (S(i) - S(j))^2 \quad (24)$$

$S(i)$  和  $S(j)$  分别表示节点  $i$  和  $j$  的所要求的显著值， $S_{in}(i)$  是节点  $i$  的初始显著值， $\lambda$  是规范化系数。其中等式右边第一项是 fitting constraint，表示一幅好的显著图与初始显著图之间不会变化太多。第二项是 smoothness constraint，一幅好的显著图上相邻超像素的显著值不会相差太多。超像素上的最优显著值是通过最小化该 cost function 来计算。令该方程关于  $S$  的导数为 0 可得

$$S^* = \mu(D - W + \mu I)^{-1} S_{in} \quad (25)$$

其中  $D$  是三角矩阵, 并且有  $d_{ii} = \sum_j (w_{ij})$ ,  $\mu = 1/(2\lambda)$ 。

## 5.7 Focusness Prior

论文 [8] 中将 focusness 定义为焦点模糊程度。

# 6. Feature Contrasts/Priors 的融合

## 6.1 相乘

对相乘融合而言, 要保证相乘的量取值在  $[0, 1]$  之间。

目前来看, 分为两种。

1. 求出两个区域间关于多种关于 visual cues 的对比度之后, 要先将这些对比度融合, 例如可以相乘, 求出最终的对比度公式。然后再对每个区域计算 local 或 global contrast。

论文 [23] 中, 两个区域  $r_i$ 、 $r_j$  间的最终的对比度定义如下:

$$D_r(r_i, r_j) = D_c(r_i, r_j) \cdot \exp[\sigma_e^2 \cdot D_e(r_i, r_j)] \quad (26)$$

其中  $D_c(r_i, r_j)$  是指 color contrast,  $D_e(r_i, r_j)$  是指 visual complexity contrast。

对每个区域  $r_i$ , 其空间加权 global contrast 定义为:

$$U(r_i) = \sum_{j \neq i} w_{ij} \cdot D_r(r_i, r_j) \cdot \phi_j \quad (27)$$

$$w_{ij} = \frac{1}{Z_i} \cdot \exp[-\sigma_s^2 \cdot D_s(r_i, r_j)] \quad (28)$$

其中,  $\phi_j$  是指区域  $r_j$  内的像素个数, 即区域  $r_j$  的大小。  $D_s(r_i, r_j)$  表示区域  $r_i$  和  $r_j$  之间的空间距离。  $\phi_s$  则用来控制空间加权  $w_{ij}$  的影响程度,  $\phi_s$  越大, 对  $U(r_i)$  的影响越小。  $\frac{1}{Z_i}$  是归一化因子, 保证  $\sum_{j \neq i} w_{ij} = 1$ 。

2. 对每个 visual cue 求出 local 或 global contrast 之后, 再对这些对比度进行融合。

例如论文 [19] 中,

方法 PBS [20] 中在求初始显著图时先计算了 spatially weighted contrast

$$S_{co}(i) = \sum_{j \neq i} \|c_i - c_j\| \cdot \exp\left(-\frac{\|p_i - p_j\|^2}{2\sigma_p^2}\right) \quad (29)$$

然后又计算了 convex-hull-based center prior map, 即首先估计显著目标的中心位置  $(x_0, y_0)$ , 再计算每个超像素  $i$  的显著性:

$$S_{ce}(i) = \exp\left(-\frac{\|x_i - x_0\|^2}{2\sigma_x^2} - \frac{\|y_i - y_0\|^2}{2\sigma_y^2}\right) \quad (30)$$

最后将两者相乘得到初始显著图

$$S_{in}(i) = S_{co}(i) \times S_{ce}(i) \quad (31)$$

## 6.2 相加

## 6.3 利用机器学习进行优化

### 6.3.1 最小二乘法

1、论文 [24] 中是通过最小二乘实现全局优化。其中的 cost function 如下:

$$\sum_{i=1}^N w_i^{bg} s_i^2 + \sum_{i=1}^N s_i^{fg} (s_i - 1)^2 + \sum_{i,j} w_{ij} (s_i - s_j)^2 \quad (32)$$

其中第一项是背景约束, 当某区域的  $w_i^{bg}$  较大时, 是背景的概率较大, 方程的第一项占的比重较多, 为使整个方程值最小, 需使  $s_i$  近似为 0, 也就是使该区域的显著性近似为 0。第二项是前景约束, 当某区域的  $w_i^{fg}$  较大时, 第二项占的比重较大, 需使  $s_i$  近似为 1。  $w_i^{fg}$  可以通过目前已有的一些显著性方法或它们的组合来计算。第三项是平滑约束, 保证显著值的连续性,  $w_{ij}$  定义如下:

$$w_{ij} = \exp\left(-\frac{d_{app}^2(p_i, p_j)}{2\sigma_{clr}^2}\right) + \mu \quad (33)$$

超像素  $p_i$  与  $p_j$  越相似,  $d_{app}(p_i, p_j)$  越小,  $w_{ij}$  越大, 越需要  $s_i, s_j$  近似相等。

2、方法 PBS [20] 中求最终显著图时用到如下 saliency cost function:

$$E(S) = \sum_i (S(i) - S_{in}(i))^2 + \lambda \sum_{i,j} w_{ij} (S(i) - S(j))^2 \quad (34)$$

$S(i)$  和  $S(i)$  分别表示节点  $i$  和  $j$  的所要求的显著值,  $S_{in}(i)$  是节点  $i$  的初始显著值,  $\lambda$  是规范化系数。其中等式右边第一项是 fitting constraint, 表示一幅好的显著图与初始显著图之间不会变化太多。第

二项是 smoothness constraint, 一幅好的显著图上相邻超像素的显著值不会相差太多。超像素上的最优显著值是通过最小化该 cost function 来计算。

### 6.3.2 条件随机场

条件随机场 (Conditional Random Fields, CRFs) 最早由 Lafferty 等人 [10] 于 2001 年提出, 其模型思想主要来源于最大熵模型。

### 6.3.3 马尔可夫随机场

## 参考文献

- [1] Kai-Yueh Chang, Tyng-Luh Liu, Hwann-Tzong Chen, and Shang-Hong Lai. Fusing generic objectness and visual saliency for salient object detection. In *Computer Vision (ICCV), 2011 IEEE International Conference on*, pages 914–921. IEEE, 2011.
- [2] Ming-Ming Cheng, Guo-Xin Zhang, Niloy J Mitra, Xiaolei Huang, and Shi-Min Hu. Global contrast based salient region detection. In *Computer Vision and Pattern Recognition (CVPR), 2011 IEEE Conference on*, pages 409–416. IEEE, 2011.
- [3] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *Computer Vision and Pattern Recognition, 2005. CVPR 2005. IEEE Computer Society Conference on*, volume 1, pages 886–893. IEEE, 2005.
- [4] Pedro F Felzenszwalb, Ross B Girshick, David McAllester, and Deva Ramanan. Object detection with discriminatively trained part-based models. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, 32(9):1627–1645, 2010.
- [5] Bowen Jiang, Lihe Zhang, Huchuan Lu, Chuan Yang, and Ming-Hsuan Yang. Saliency detection via absorbing markov chain. In *Computer Vision (ICCV), 2013 IEEE International Conference on*, pages 1665–1672. IEEE, 2013.
- [6] Huaizu Jiang, Jingdong Wang, Zejian Yuan, Tie Liu, Nanning Zheng, and Shipeng Li. Automatic salient object segmentation based on context and shape prior. In *BMVC*, volume 6, page 7, 2011.



- [7] Huaizu Jiang, Jingdong Wang, Zejian Yuan, Yang Wu, Nanning Zheng, and Shipeng Li. Salient object detection: A discriminative regional feature integration approach. In *Computer Vision and Pattern Recognition (CVPR), 2013 IEEE Conference on*, pages 2083–2090. IEEE, 2013.
- [8] Peng Jiang, Haibin Ling, Jingyi Yu, and Jingliang Peng. Salient region detection by ufo: Uniqueness, focusness and objectness. In *Computer Vision (ICCV), 2013 IEEE International Conference on*, pages 1976–1983. IEEE, 2013.
- [9] Jiwhan Kim, Dongyoon Han, Yu-Wing Tai, and Junmo Kim. Salient region detection via high-dimensional color transform. In *Computer Vision and Pattern Recognition (CVPR), 2014 IEEE Conference on*, pages 883–890. IEEE, 2014.
- [10] John Lafferty, Andrew McCallum, and Fernando CN Pereira. Conditional random fields: Probabilistic models for segmenting and labeling sequence data. 2001.
- [11] Xi Li, Yao Li, Chunhua Shen, Anthony Dick, and Anton Van Den Hengel. Contextual hypergraph modeling for salient object detection. In *Computer Vision (ICCV), 2013 IEEE International Conference on*, pages 3328–3335. IEEE, 2013.
- [12] David G Lowe. Object recognition from local scale-invariant features. In *Computer vision, 1999. The proceedings of the seventh IEEE international conference on*, volume 2, pages 1150–1157. Ieee, 1999.
- [13] David G Lowe. Distinctive image features from scale-invariant keypoints. *International journal of computer vision*, 60(2):91–110, 2004.
- [14] Song Lu, Vijay Mahadevan, and Nuno Vasconcelos. Learning optimal seeds for diffusion-based salient object detection. In *Computer Vision and Pattern Recognition (CVPR), 2014 IEEE Conference on*, pages 2790–2797. IEEE, 2014.
- [15] Mark Nixon, Mark S Nixon, and Alberto S Aguado. *Feature extraction and image processing for Computer Vision*. Academic Press, 2012.
- [16] Timo Ojala, Matti Pietikainen, and David Harwood. Performance evaluation of texture measures with classification based on kullback discrimination of distributions. In *Pattern Recognition, 1994. Vol. 1-Conference A: Computer Vision & Image Processing., Proceedings of the 12th IAPR International Conference on*, number 1, pages 582–585, 1994.

- [17] Bolan Su, Shijian Lu, and Chew Lim Tan. Blurred image region detection and classification. In *Proceedings of the 19th ACM international conference on Multimedia*, pages 1397–1400. ACM, 2011.
- [18] Yichen Wei, Fang Wen, Wangjiang Zhu, and Jian Sun. Geodesic saliency using background priors. In *Computer Vision–ECCV 2012*, pages 29–42. Springer, 2012.
- [19] Qiong Yan, Li Xu, Jianping Shi, and Jiaya Jia. Hierarchical saliency detection. In *Computer Vision and Pattern Recognition (CVPR), 2013 IEEE Conference on*, pages 1155–1162. IEEE, 2013.
- [20] Chuan Yang, Lihe Zhang, and Huchuan Lu. Graph-regularized saliency detection with convex-hull-based center prior. *Signal Processing Letters, IEEE*, 20(7):637–640, 2013.
- [21] Chuan Yang, Lihe Zhang, Huchuan Lu, Xiang Ruan, and Ming-Hsuan Yang. Saliency detection via graph-based manifold ranking. In *Computer Vision and Pattern Recognition (CVPR), 2013 IEEE Conference on*, pages 3166–3173. IEEE, 2013.
- [22] Lin Zhang, Zhongyi Gu, and Hongyu Li. Sdsp: A novel saliency detection method by combining simple priors. In *ICIP*, pages 171–175. Citeseer, 2013.
- [23] Guokang Zhu, Qi Wang, and Yuan Yuan. Tag-saliency: Combining bottom-up and top-down information for saliency detection. *Computer Vision and Image Understanding*, 118:40–49, 2014.
- [24] Wangjiang Zhu, Shuang Liang, Yichen Wei, and Jian Sun. Saliency optimization from robust background detection. In *Computer Vision and Pattern Recognition (CVPR), 2014 IEEE Conference on*, pages 2814–2821. IEEE, 2014.